

Vorregistrierung der Abschlussarbeit im Empirischen Projektmodul

Kleingruppe: A

Vor- und Nachnamen der Studierenden:

Patrica Hünemörder, Emma Neu, Celina Kuhn, Julia Häußer

Datum: 24.04.2025

1. Hypothese: Welche Hauptfragestellung/-hypothese soll in der Arbeit beantwortet werden?

Wir untersuchen die Fragestellung, ob ein positiver Zusammenhang zwischen der Antizipationsfähigkeit und der individuellen Exposition gegenüber Druckmedien (gemessen durch die ART-Leistung) besteht.

Wir betrachten dafür ausschließlich den Block A (High Validity) und die Antizipationsleistung der Versuchspersonen im Testblock nach dem High Validity Training. Die Adaption an die High beziehungsweise Low Validity Bedingung wird nicht explizit betrachtet, da sie nicht zur Überprüfung der Hypothese beiträgt.

Versuchsaufbau:

Die Studie besteht aus zwei Blöcken (A und B), die jeweils eine Trainings- und eine Testphase beinhalten.

Im Block A (High Validity) kann bei 75% der Sätze Antizipation genutzt werden, um die nach dem Target folgenden Wörter vorherzusagen, was in einer kürzeren Lesezeit resultiert. Die Versuchspersonen werden in dieser Trainingsphase somit darauf trainiert, Antizipation zu nutzen.

Im Block B (Low Validity) hingegen ist nur bei 25% der Sätze eine Vorhersagbarkeit der nachfolgenden Wörter möglich, sodass die Teilnehmenden lernen, auf Antizipation zu verzichten.

In den Testphasen sind jeweils 50% der Wörter vorhersagbar und 50% nicht vorhersagbar. Das Hauptaugenmerk liegt hierbei auf der Verweildauer der Teilnehmenden auf den einzelnen Satzbestandteilen beim Lesen dieser.

2. Abhängige Variable: Beschreiben Sie die abhängige(n) Variable(n). Wie wird/werden diese gemessen? Auf welcher Skala oder in welcher Einheit?

Unsere AV ist die Reaktionszeitdifferenz beim Lesen vorhersagbarer und unvorhersagbarer Wörter (Reaktionszeitdifferenz = unvorhersagbar – vorhersagbar). Gemessen wird diese im Testblock A (High Validity), in dem die Vorhersage strategisch sinnvoll ist. Sie wird intervallskaliert in Sekunden gemessen und angegeben. Die kritische Region der AV ist das erste Wort nach dem Target, also die sogenannte Spill-Over-Region. Grund dafür ist, dass sich die Effekte des Targets in der Regel nicht direkt, sondern erst zeitlich verzögert zeigen (Spill-Over-Effekt).

3. Unabhängige Variablen: Beschreiben Sie die unabhängige(n) Variable(n). Wie werden diese gemessen (kategorisch oder kontinuierlich)? Bei faktoriellen Variablen, geben Sie die Namen des Faktors und die Namen der Stufen an. Geben Sie für jede Variable an, ob sie *within*- oder *between-subjects* gemessen wird!

Unsere UV ist die individuelle Exposition gegenüber Druckmedien, welche das Leseverhalten der Proband:innen im Alltag beschreibt. Operationalisiert wird diese durch die Performanz im ART (Author-Recognition-Test).

Diese wird berechnet, indem die Anzahl der falsch genannten Autor:innen von der Anzahl der korrekt genannten subtrahiert wird (Performanz = Hits – False Alarms).

Die UV wird kontinuierlich gemessen. Es handelt sich bei dieser um eine *between-subjects* Variable, da nicht die veränderten Leistungen einer einzelnen Versuchsperson, sondern die (relativ) stabilen Leistungen mehrerer Versuchspersonen erhoben und miteinander verglichen werden.

4. Analysen: Spezifizieren Sie exakt, welche Analysen bzw. statistischen Tests Sie vornehmen möchten, um die Hauptfragestellung/-hypothese zu untersuchen.

Zur Überprüfung der Hauptfragestellung möchten wir eine Produkt-Moment-Korrelation nach Pearson durchführen. Dabei wird ein einseitiger (rechtsseitiger) Test angewendet, da wir einen positiven Zusammenhang zwischen der Antizipationsleistung und der individuellen Exposition gegenüber Druckmedien (gemessen durch die ART-Leistung) erwarten. Die Nullhypothese ($H_0: r \leq 0$) wird gegen die gerichtete Alternativhypothese ($H_1: r > 0$) getestet.

5. Weiterführende Analysen: Werden weitere, z.B. explorative, Analysen durchgeführt?

Für diese Studie haben wir keine weiteren Analysen durchgeführt.

6. Stichprobengröße: Geben Sie an, wie sie die Stichprobenumfangsplanung durchgeführt haben. Wie viele Probanden benötigen Sie, um die Hauptfragestellung zu beantworten?

Mit der Funktion “pwr.r.test” aus dem Paket “pwr” haben wir mithilfe des Statistikprogramms R eine Poweranalyse (einseitige Testung (rechtsseitig)) für eine Power von 0.8 mit dem Signifikanzlevel 0.05 und einer mittleren Effektgröße von $|r| = 0.30$ (Taxonomievorschlag nach Cohen) durchgeführt. Die Berechnung im Anhang (vgl. Abbildung 1) zeigt, dass hierfür eine Stichprobe von 67 Proband:innen notwendig wäre.

Da wir eine größere Stichprobe erwarten und die Daten für die Studie bereits vorliegen, haben wir mithilfe der Pakete “ggplot2” und “pwr” den Verlauf der Effektstärke (bei einer Power von 0.8 und einem Signifikanzlevel von 0.05) in Abhängigkeit der Stichprobengröße dargestellt (vgl. Abbildung 2; Abbildung 3).

Hieran lässt sich zeigen, dass es erst ab einer Stichprobengröße von 600 Proband:innen möglich wäre, einen kleinen Effekt ($|r| = 0.10$; Taxonomievorschlagnach Cohen) aufzudecken. Dies haben wir in Abbildung 4 noch einmal durch die Funktion “pwr” überprüft, welche ausgab, dass wir hierfür eine Stichprobe von 617 Proband:innen benötigen würden, welche wir voraussichtlich nicht erreichen werden.

Abbildung 3 zeigt ebenfalls, dass mit einer maximalen Stichprobengröße von 400 Proband:innen, welche voraussichtlich erreicht werden kann, ein kleiner bis mittlerer Effekt der Größe $|r| = 0.13$ nach Cohen erreicht werden kann.

Dies haben wir in Abbildung 5 durch die Funktion “pwr” geprüft.

Somit benötigen wir eine Stichprobengröße von 364 Proband:innen um einen kleinen bis mittleren Effekt von $|r| = 0.13$ (Taxonomievorschlagnach Cohen) bei einer Power von 0.8 und einem Signifikanzlevel von 0.05 aufdecken zu können.

Für eine genauere Schätzung wiederholten wir die Visualisierung des Verlaufs der Effektstärke in Abhängigkeit von der Stichprobengröße bei einer Power von 0.8 und einem Signifikanzlevel von 0.05 per Monte-Carlo-Simulation (vgl. Abbildung 6; Abbildung 7).

Zuletzt überprüften wir per Monte-Carlo-Simulation die oben berechneten Parameter für unsere Stichprobe. Wir berechneten somit die Power bei einer Stichprobengröße von 364 Proband:innen für einen kleinen bis mittleren Effekt von $|r| = 0.13$ (Taxonomievorschlagnach Cohen) und einem Signifikanzlevel von 0.05. Wir erhielten eine Power von 0.801, weshalb wir bei diesen Parametern verbleiben (vgl. Abbildung 8).

7) Anhänge: Screenshots aus R, wo zutreffend.

```
##{r}
pwr.r.test(power = 0.8, r = 0.30, sig.level = 0.05, alternative = "greater")

approximate correlation power calculation (arctangh transformation)

      n = 66.55463
      r = 0.3
sig.level = 0.05
  power = 0.8
alternative = greater
```

Abbildung 1

Stichprobenumfangsplanung bei mittlerer Effektgröße. Eigene Darstellung, erstellt mit RStudio.

```
{r}

# Vektor mit verschiedenen Stichprobengrößen
n_values <- seq(20, 700, by = 10)

# Für jede Stichprobengröße die Effektstärke berechnen, die eine Power von 0.8 ergibt
effect_sizes <- sapply(n_values, function(n) {
  pwr.r.test(n = n, sig.level = 0.05, power = 0.8, alternative = "greater")$r
})

# Datenframe erstellen
df_effectsize_n <- data.frame(
  SampleSize = n_values,
  EffectSize = effect_sizes
)

# Plot: Effektstärke in Abhängigkeit der Stichprobengröße
ggplot(df_effectsize_n, aes(x = SampleSize, y = EffectSize)) +
  geom_line(color = "steelblue", size = 1.2) +
  geom_point(color = "grey", size = 1) +
  labs(
    title = "Effektstärke für Power = 0.8 in Abhängigkeit der Stichprobengröße",
    x = "Stichprobengröße (n)",
    y = "Effektstärke (r)"
  ) +
  theme_minimal()
}
```

Abbildung 2

Visualisierung der Effektgröße in Abhängigkeit der Stichprobengröße. Eigene Darstellung, erstellt mit RStudio.




Abbildung 3

Diagramm - Effektgröße in Abhängigkeit der Stichprobengröße. Eigene Darstellung, erstellt mit RStudio.

```
## {r}  
pwr.r.test(power = 0.8, r = 0.10, sig.level = 0.05, alternative = "greater")
```

```
approximate correlation power calculation (arctangh transformation)  
  
n = 616.1032  
r = 0.1  
sig.level = 0.05  
power = 0.8  
alternative = greater
```

Abbildung 4

Stichprobenumfangsplanung bei kleiner Effektgröße. Eigene Darstellung, erstellt mit RStudio.

```
## {r}  
pwr.r.test(power = 0.8, r = 0.13, sig.level = 0.05, alternative = "greater")
```

```
approximate correlation power calculation (arctangh transformation)  
  
n = 363.6803  
r = 0.13  
sig.level = 0.05  
power = 0.8  
alternative = greater
```

Abbildung 5

Stichprobenumfangsplanung bei kleiner bis mittlerer Effektgröße. Eigene Darstellung, erstellt mit RStudio.

```
# Parameter
n_values <- seq(20, 700, by = 10)
r_values <- seq(0.01, 0.8, by = 0.01) # getestete Effektstärken
n_sim <- 1000 # Anzahl der Monte Carlo Simulationen
alpha <- 0.05 # Signifikanzniveau
normal_power <- 0.8 # Power

# Funktion zur Monte-Carlo Power-Berechnung für eine gegebene Effektstärke und Stichprobengröße
simulate_power <- function(n, r, n_sim = 1000, alpha = 0.05) {
  p_values <- replicate(n_sim, {
    x <- rnorm(n)
    y <- r * x + sqrt(1 - r^2) * rnorm(n) # erzeugt y mit Korrelation r zu x
    test <- cor.test(x, y, alternative = "greater")
    test$p.value
  })
  mean(p_values < alpha) # geschätzte Power
}

# Leere Vektoren für Ergebnisse
effect_sizes <- numeric(length(n_values))

# Simulation: finde für jede Stichprobengröße die kleinste Effektstärke mit Power ≥ 0.8
for (i in seq_along(n_values)) {
  n <- n_values[i]
  cat("Berechne für n =", n, "\n")
  for (r in r_values) {
    power <- simulate_power(n, r, n_sim, alpha)
    if (power >= normal_power) {
      effect_sizes[i] <- r
      break
    }
  }
}

# Daten zusammenführen
df_effectsize_n <- data.frame(
  SampleSize = n_values,
  EffectSize = effect_sizes
)

# Plot
ggplot(df_effectsize_n, aes(x = SampleSize, y = EffectSize)) +
  geom_line(color = "steelblue", size = 1.2) +
  geom_point(color = "grey", size = 1) +
  labs(
    title = "Monte-Carlo: Effektstärke für Power = 0.8",
    x = "Stichprobengröße (n)",
    y = "Effektstärke (r)"
  ) +
  theme_minimal()
```

Abbildung 6

Visualisierung der Effektgröße in Abhängigkeit der Stichprobengröße per Monte-Carlo-Simulation. Eigene Darstellung, erstellt mit RStudio.




Abbildung 7

Diagramm - Effektgröße in Abhängigkeit der Stichprobengröße (per Monte-Carlo-Simulation). Eigene Darstellung, erstellt mit RStudio.

```
```{r}
Pakete installieren und laden

library(simr)
library(pwr)

Funktion zur Simulation von Spearman-Korrelation (Monte-Carlo-Simulation)
simulate_power <- function(n = 364, rho = 0.13, alpha = 0.05, reps = 1000) {
 significant_results <- 0

 for (i in 1:reps) {
 # Generiere zwei zufällige, korrelierte Variablen mit Spearman's Rho
 x <- rnorm(n)
 y <- rho * x + sqrt(1 - rho^2) * rnorm(n) # Erzeugt Korrelation
 R_test <- cor.test(x, y, method = "pearson", alternative = "greater")

 # Prüfe, ob das Ergebnis signifikant ist; wenn ja erhöhe significant_results um 1
 if (R_test$p.value < alpha) {
 significant_results <- significant_results + 1
 }
 }

 # Berechne die Power (Anteil signifikanter Tests)
 power_estimate <- significant_results / reps
 return(power_estimate)
}

Gibt Ergebnisse aus
power_result <- simulate_power()
print(power_result)
```
```

```
[1] 0.801
```

Abbildung 8
Powerberechnung kleiner bis mittlerer Effekt (per Monte-Carlo-Simulation). Eigene Darstellung, erstellt mit RStudio.